

内生参照场与体验归属：慢变共享调制假说及其判别性检验

Endogenous Reference Fields and Experiential Attribution: A Slow
Shared-Modulation Hypothesis and Its Discriminating Tests

刘烘炬 (Hongju Liu) · 独立研究者, 中国深圳

TA-TR-2026-10 · v1.1 · 2026-09-20

DOI: [10.5281/zenodo.22854705](https://doi.org/10.5281/zenodo.22854705)

Revised version of v1.0: [10.5281/zenodo.22852885](https://doi.org/10.5281/zenodo.22852885)

状态: 非同行评审预印本; CC BY 4.0; 含实质 AI 辅助, 作者承担发表责任。

摘要

本文提出内生参照场 (Endogenous Reference Field, ERF) 假说: 参照型体验可能由一种慢变、受内容反复更新、同时调制多个内容通道的因果组织实现。共享调制、内容维持与时间尺度分离构成组织识别条件; 体验归属仍需额外的桥接假说, 不能由定义或数值阈值推出。

本文以框架依赖性为结构对应的动机, 与情境调制、树突信息理论 (DIT)、IIT、GWT 和功能主义作条件明确的比较。形式部分区分调制强度、返回影响、分解距离、响应分化与内在持续。对保持干预协议的位点传递系统, 证明同一对称轨道内的持续画像相同; 该结果排除指定对称粒度上的严格快慢分离, 不排除所有宏观组织, 也不构成对 IIT 4.0 的直接反证。

一项三任务、每任务三个固定种子的小规模计算实验显示: 相同的二维状态空间架构, 经不同任务训练后, 在指定探针下形成长期保持的共享调制、近零共享调制和快速衰减共享调制等不同画像。经验平均调制与理论上确界严格区分; 非零残差不被四舍五入为本体论上的零。该实验支持组织画像受训练塑造, 但仅测量状态保持、跨通道调制和事件更新, 不独立验证完整 ERF, 更不证明机器具有意识。附录 A 的有限构造核验与附录 C 的训练实验是不同证据。本文提出可受经验挑战的预测, 并明确粒度、干预可实现性及体验桥接尚未解决的限制。

关键词: 意识; 参照组织; 情境调制; 时间尺度分离; 判别性检验; 人工智能

Abstract

We propose endogenous reference fields (ERFs) as a hypothesis linking reference-dependent experience to slow, content-updated states that jointly modulate multiple content channels. Shared modulation, content maintenance, and timescale separation identify a candidate organization; experiential attribution remains a separate bridging hypothesis. We distinguish modulation, mediated return influence, decomposition distance, response differentiation, and intrinsic persistence. A symmetry argument establishes equal persistence profiles within a transitive orbit under an invariant intervention protocol, excluding strict timescale separation at that specified grain rather than at every possible macroscopic grain. Conditional contrasts with IIT, global workspace theories, functionalism, dendritic information theory, and artificial

architectures clarify the proposal’s commitments. A small computational proof of concept trains the same two-dimensional state-space architecture on three tasks with three fixed seeds each. The resulting probe-dependent profiles exhibit sustained shared modulation, near-zero modulation, or rapidly decaying modulation. Finite-sample mean modulation is distinguished from the theoretical supremum, and numerical residuals are not treated as exact zeros. The experiment supports training-dependent organizational variation, while neither establishing the complete ERF criteria nor demonstrating machine consciousness. Finite construction checks and training experiments are reported separately. Empirical predictions address the bridging hypothesis, whose necessity and sufficiency remain conjectural.

Keywords: consciousness; reference organization; contextual modulation; timescale separation; discriminating tests

1 问题与核心主张

本文的核心假说是：参照型体验与一种慢于内容变化、由内容反复更新、共同改变多个内容通道处理方式的组织相联系。必要性方向认为这种组织是参照型体验的必要条件；充分性方向认为实际运行这种组织可实现参照型体验。二者都不是数学定理。第 5 节说明结构对应动机，第 7 节给出经验挑战方式。

这一主张增加了特定约束。IIT 4.0 从现象公理与因果结构建立其理论，不要求本文形式的慢变参照，也不能简单概括为“任意高整合就有意识”（Albantakis et al., 2023）。GWT/GNWT 强调内容的全局可用性及其动态实现，而 ERF 强调处理规则的共享调制。一般功能主义并不等同于输入输出行为主义；本文仅与“普通输入输出等价足以决定体验归属”的强立场直接分歧，与承认内部因果角色的功能主义未必冲突。

本文不判定任何现有人工系统是否具有意识。其任务是明确一个可批评的假说、若干有限判别案例，以及可复现的组织测量。体验至少涉及内容分化、时间维持、跨通道联系和情感效价；本文主要处理前三者，效价与具体感受质留作开放问题。任务智能另行记录，不作为体验指标。

2 近邻理论与本文增量

ERF 最近的近邻不是 IIT，而是神经科学中的情境调制研究。

- **情境调制与增益调制。** Phillips 等人把皮层中的情境调制描述为：情境输入改变前馈信号的增益和意义，但不单独驱动输出（Phillips et al., 2015）。Salinas 与 Sejnowski 总结了增益调制在感知和行为中的普遍作用（Salinas & Sejnowski, 2001）。ERF 所说的“参照改变内容角色”，正是这类作用的抽象版本。
- **树突信息理论（DIT）。** Aru、Suzuki 与 Larkum 提出，意识依赖锥体神经元顶树突（接收情境反馈）与基树突（接收前馈内容）的耦合（Aru et al., 2020）；麻醉剂可切断这一耦合（Suzuki & Larkum, 2020）。这是 ERF 在细胞层面最直接的经验对应。
- **IWMT 与投射意识模型**已把视角参照置于中心（Safron, 2020; Williford et al., 2018）。
- **IIT 4.0** 以整合与排他性选择主体（Albantakis et al., 2023）；**GWT** 以全局广播为核心（Dehaene & Changeux, 2011）。

本文的增量有三点，每一点都可被单独检验：

1. **与基质无关的判据。** DIT 和情境调制研究针对神经元。本文把它们共同结构抽象为三条可在任意因果模型中执行的判据（第 3 节），因此可以用于人工系统。

2. **时间尺度分离是必要条件。** 本文不主张近邻工作忽略时间动力学；相较于只要求存在调制的弱表述，本文要求调制状态比内容更慢，并把快慢比作为分级画像的一部分。正是这一条区分出 ERF 与 IIT、功能主义的判断（第 6 节）。
3. **判别性预测。** 本文列出 ERF 与近邻理论结论相左的案例，以及可推翻 ERF 的经验结果（第 7 节）。

与 DIT 的关系需要单独说明，因为二者最容易被混为一谈。 两者在一点上预测相同：选择性切断情境调制而保留前馈内容，体验应当减弱（第 7 节 P1）。分歧有三处：

问题	DIT	ERF
适用对象	锥体神经元及其树突区室	任意可干预的因果系统
调制是否必须慢于内容	未规定本文的严格持续期不等	式必须，且快慢比是画像分量
同质网格、广播总线、人工架构	不适用	给出有条件的组织判断（第 6 节）

因此 P1 的结果不能区分 ERF 与 DIT；P2、P3 提供更具体的时间尺度检验，但并非已证明为 ERF 独有。命题 6 是 ERF 定义在限定粒度上的后果；DIT 未对人工同质网格作判断并不等于持相反判断。

调制强度、分解距离、打包数等数学工具都是现成的，本文不主张它们的首创。

3 参照的识别判据

若只把参照定义为”研究者指定的调制变量”，任何双输入函数只要存在交互，都可以把其中一个输入命名为参照。本节用三条判据取代命名。

3.1 分析单位：可局部干预的位点

给定有限因果模型 $\mathcal{M}$ 、允许干预集合 $\mathcal{I}$ 、背景协议 b 与时间窗 H 。一个**位点**是 $\mathcal{M}$ 中可以用单次局部干预设定其状态、且在多个时刻持续存在的物理自由度。位点由物理接口确定，而不是由方程中的变量名确定。

3.2 基本量：调制、滞后调制与内在持续

固定因果模型、允许干预和背景协议后，对位点 R 与内容通道 $X_i \rightarrow Y_i$ 定义分布交互对比。因果交互分析是已有方法（VanderWeele, 2015）；下式是本文使用的具体分布版本。

$$K_i^r(a) = P(Y_i \mid \text{do}(R = r), \text{do}(X_i = a); b),$$

$$m_i = \sup_{r, r', a, a'} \frac{1}{2} \|K_i^r(a) - K_i^r(a') - K_i^{r'}(a) + K_i^{r'}(a')\|_1.$$

所有上确界只遍历允许的状态、内容探针及声明的背景范围， $0 \leq m_i \leq 2$ 。这里是四项分布对比的半 L^1 范数，不是两个概率分布之间的普通总变差。

滞后调制在 t 时刻设定 R ，之后释放，在 $t + s$ 设定内容并观察响应。记相应响应核为 $K_{i,s}^r(a)$ ，则

$$m_i(s) = \sup_{r, r', a, a'} \frac{1}{2} \|K_{i,s}^r(a) - K_{i,s}^r(a') - K_{i,s}^{r'}(a) + K_{i,s}^{r'}(a')\|_1.$$

离散更新可把输出记为 $Y_{i,t+s+1}$ ；附录 C 的代码在完成当前更新后立即读出，使用 $t + s$ 的读出索引。二者须按事件顺序对齐。

内在持续阻断经其他位点返回的路径。对位点或已声明的位点集合 z ，在 t 时刻设为 v 或 v' ，并把补集 $\bar{z}$ 的后续轨迹夹持为同一基准自然轨迹。记由此得到的状态分布为 $P_{z,s}^{v,b}$ ，定义

$$\pi_z(s) = \sup_{b,v,v'} d_{\text{TV}}(P_{z,s}^{v,b}, P_{z,s}^{v',b}), \quad L_z = \max(\{s \in \{1, \dots, H\} : \pi_z(s) > 0\} \cup \{0\}).$$

b 包含允许的初态、输入和基准轨迹。 $L_z = H$ 只说明在窗内仍有影响，不给出窗外持续期。该量记录非零影响的支持范围，而不是振幅衰减速度；两个非零指数衰减可有相同 L_z 。确定性连续状态的不同点质量之间总变差恒为 1，因此数值差的范数保留率不能冒充 π_z 。经验研究应另报振幅曲线、噪声模型和不确定性，不能以任意截断把残差宣布为零。

3.3 三条判据

在明确接口、背景和粒度的精确模型中，候选组织满足以下三项条件时，称为 ERF 组织：

1. **共享调制。** 存在同一允许的 R 干预对 (r, r') 和兼容背景，使至少两个不同内容通道的四项交互对比非零。分别在不兼容的背景下取得两个上确界，不足以证明共享。单门两个输入的交互只涉及一个通道。
2. **内容维持。** 同一声明的内容集合可在持续期内的多个时刻对 R 的更新产生非零干预效应，而不只是图中存在形式路径。这里的“维持”指反复更新的能力，不等于每次更新都增加稳定性。只在生成时写入、此后只读的状态不满足此条件。若实际更新来自独立控制信号，必须明确写出，不能直接当作被调制内容的反馈。
3. **时间尺度分离。** 在同一声明的比较协议下， $L_R > \max_x L_x$ ，且超过相应内容持续期后，至少两个通道仍可由同一参照干预对调制。该精确支持条件不保证振幅意义的显著慢变；“慢变”程度还须由完整曲线描述。

3.4 分级而不是意识开关

上述条件在精确模型中有成立与否；这不等于经验意识的二分判定。本文不设任意意识阈值，不把多个分量加权合成意识总分，而报告以下画像。

分量	含义与限制
共享广度	同一兼容干预下受调制的通道数
调制	理论 $m_i(s)$ 或另行命名的经验平均曲线
持续	精确 L_R, L_x ，以及经验振幅衰减曲线
响应分化	声明响应任务下的 $N_H(\eta)$ 曲线
返回与分解	经参照的返回效应和相对于分割的分解距离

当 $L_x = 0$ 时， L_R/L_x 未定义，报告两个持续期或差值，不写“很大的快慢比”。正的支持范围、有限样本检测结果和体验归属属于三个不同层次。

3.5 引理 1：判据对重编码不变

若两个描述通过逐位点的双射对应，且保持同一组物理干预接口，则三条判据的成立与否及上述以分布距离定义的理论画像分量不变。

证明：双射把响应分布推送到重标记空间，总变差距离不变；位点由接口定义，因此“单次局部干预”的含义不随坐标改变。于是，把 x 、 y 混合成 $u = x + y$ 与 $v = x - y$ ，并不产生一个可以被单次局部干预设定的新位点，也就不能靠变量代换制造参照。

3.6 粒度规则：由读取者决定

判据 3 要求在同一粒度上比较参照与内容。但大脑中的慢变参照很可能是许多神经元共同维持的状态，而内容单元的规模不同。本文不按位点个数对齐粒度，而是按下游机制实际读取的变量对齐。

读取变量。 固定机制的其余输入和干预范围，要求等价在全部这些条件下成立。设机制 M 的更新只经由位点集合 S 的某个粗粒化 $f(S)$ 依赖于 S ： S 的两个微观状态若 f 值相同， M 的响应核也相同。取满足这一条件的最粗的 f ，称 $f(S)$ 为 M 所读取的变量。

规则。 参照的持续按内容通道读取参照时所用的变量计算，内容的持续按下游机制读取内容时所用的变量计算。 $L_R > L_x$ 比较的是这两个读取变量的内在持续期，与各自包含的位点数无关。

这一规则有两个后果：

1. **它不允许靠任意打包制造慢变量。** 一个没有任何机制读取的宏观量，即使守恒，也不算参照。例如 150 号元胞自动机环的全局奇偶守恒，但环上每条规则只读取邻域，全局奇偶不是任何机制的读取变量。
2. **命题 6 只在对称对应的读取粒度上延伸。** 必须额外要求所比较的块、读取映射与宏观干预协议都由同一自同构轨道对应。单位点传递本身不保证不同形状或不同读出功能的宏观变量具有相同持续画像。

这条规则的代价是：识别读取变量需要知道下游机制的依赖结构。在神经系统中，这相当于要求说明某个群体状态是被哪些下游神经元、以何种聚合方式读取的。这是经验问题，不是可以先验解决的问题。粗粒化值的干预还须规定如何选择对应微观状态；没有这种提升协议，宏观持续画像可能不唯一。全局奇偶没有局部读出只能排除该候选，不能排除所有集体候选。

4 组织画像的形式核心

本节的结果都是初等的，作用是说明画像为何需要多个分量，而不是提供新定理。

4.1 其余画像分量

经参照的返回影响 ρ_{ij} ：内容 i 在 t 时刻经由 R 改变内容 j 在后续时刻的角色，定义方式与 m_i 相同，只计入经路径阻断确认通过 R 的影响。

分解距离 δ_π ：对位点的分割 π ，令 $\mathcal{D}_\pi$ 为按该分割独立更新的模型类，同一个替代模型须同时对照全部干预：

$$\delta_\pi = \inf_{Q \in \mathcal{D}_\pi} \sup_{I \in \mathcal{I}} d_{TV} \left(K_{\mathcal{M}}^I, K_Q^I \right)$$

响应分化 $N_H(\eta)$ ：以内容条件在全部探针下的响应签名之间的最大总变差为伪距离 d_H ， $N_H(\eta)$ 就是内容条件集在该伪距离下的 η -打包数 (Vershynin, 2018)，即两两距离超过 η 的最大子集规模。定义要求以整条 $\eta \mapsto N_H(\eta)$ 曲线刻画；附录 C 尚未估计该分量， η 是分析分辨率，不是意识阈值。

4.2 引理

引理 2 (强度不决定分化)。固定内容条件为 $x \in \mathbb{Z}_k$ ，其余初态给定，响应包含在 $r = 0$ 下读取 x^+ ，并取 $0 \leq \eta < 1$ 。在 $\mathbb{Z}_k$ 上令 $x^+ = x + r$ ， $y^+ = y + r$ ， $r^+ = x + y$ (模 k)。对任意 $k \geq 2$ 有 $m_x = m_y = 2$ ，而 $N_H(\eta) = k$ 。因此 m 与 ρ 这类有界的上确界量不能刻画内容分化，必须单列 N_H 。

引理 3 (冗余标记不增分化)。若新增标记对全部指定响应没有影响，则任意 η 下 $N_H(\eta)$ 不变。

引理 4 (分化画像的稳定性)。在相同内容条件集和探针下，若两个模型的响应核逐一相差不超过 e ，则对 $\eta > 2e$ 有 $\tilde{N}_H(\eta + 2e) \leq N_H(\eta) \leq \tilde{N}_H(\eta - 2e)$ 。

引理 5 (行为等价不决定画像)。取输出为 y ，内容探针为对内部 x 的夹持，参照探针为对 r 的夹持。系统 A: $x_t = u_t \oplus r_t$ ， $y_t = x_t \oplus r_t$ ， $r_{t+1} = x_t$ ；系统 B: $x_t = y_t = u_t$ ， $r_{t+1} = x_t$ 。二者对全部输入序列都有 $y_t = u_t$ ，但在内部夹持接口下 $m_A = 2$ 、 $m_B = 0$ 。

引理 2 至 4 是打包数与总变差的标准性质；引理 5 是“功能等价不蕴含因果结构等价”这一熟知事实的最小实例 (Doerig et al., 2019)。引理 2 中，不同内容响应的距离为 1，故指定分辨率下打包数为 k ；四项对比可达 2。引理 3 来自响应签名不变；引理 4 由三角不等式使两两距离变化至多 $2e$ 得到；引理 5 可代入四个夹持组合验证。它们说明单独使用调制强度会丢失分化信息，普通行为等价也不固定内部干预画像；并未证明此处列出的分量是唯一或最小完备集合。

5 桥接论证：从框架依赖到参照组织

本节论证：ERF 的三条判据不是任意挑选的，而是体验中三个可观察结构特征在因果层面的对应物。这些对应为必要性猜想提供动机，但不能唯一推出三条判据；充分性也仍是假说。

5.1 三个现象结构事实

- 框架依赖**。同一刺激可以被体验为不同的东西。双稳态知觉 (Leopold & Logothetis, 1999) 中，感觉输入不变，体验却在两种组织之间切换。物理刺激不变而知觉解释改变；不能据此断言现象内容完全不变。
- 框架跨内容共享**。一个框架同时作用于多项内容。注意集或情绪状态改变的不是某一个对象，而是当下多个对象被体验的方式。
- 框架比内容更慢，且受内容塑造**。双稳态知觉中，一种解释会维持数秒并表现出滞后效应；启动与适应表明先前内容会改变后续框架。这是待量化的候选对应，不能仅从知觉持续推出某个局部位点的内在持续更长，也不能把所有注意或情绪过程都等同于有意识框架。

5.2 结构对应

现象事实	因果对应	ERF 判据
框架依赖	某状态改变内容的处理方式	调制 $m_i > 0$
跨内容共享	同一状态作用于多个通道	判据 1 共享调制

现象事实	因果对应	ERF 判据
更慢且受内容塑造	该状态由内容写入、持续更久	判据 2 内容维持、判据 3 时间尺度分离

5.3 论证形式与强度

结构对应是建立意识数学模型的一种进路（Kleiner, 2020）。即使接受体验结构应有因果实现，也不能唯一推出“同一慢变量”“局部可夹持”“内在持续”或本文读取粒度；分布式循环、适应和隐含情境变量可能提供其他实现。因此第 5.2 节是溯因式动机，不是必要性的演绎证明。

ERF 的必要性与充分性是两个可分开的桥接猜想。组织量可独立计算；把这些组织量与体验联系起来，须有独立的体验证据和竞争模型。第 7 节据此列出经验挑战，但不会把数学定义自身当作意识证据。

5.4 经验锚点

DIT 强调锥体细胞底部与顶部信息流的灵活整合（Aru et al., 2020）。Suzuki 与 Larkum（2020）在小鼠中观察到三种麻醉剂使顶树突刺激到胞体放电的耦合减弱，同时基本前馈功能相对保留。这支持研究反馈整合与意识状态的关系，但并未直接测量本文的共享调制上确界、同一参照的反复内容维持和严格时间尺度分离。麻醉伴随的变化也不能单独证明某一特征是体验的必要或充分条件。

6 判别性案例

下表保留五类判别案例，并区分精确模型结论与理论比较。

案例	ERF 组织判断	比较的准确范围
三位异或控制器 位点传递同质网格 广播与调制	指定参照缺乏持续 同一对称轨道无严格快慢分离 复制不自动等于角色调制	反对仅靠命名认定参照 与历史 IIT 网络讨论形成张力 不构成对完整 GWT/GNWT 的反证
前馈展开	声明硬件位点后可能有不同持续画像	反对仅凭普通输入输出等价归属体验
KV 条目与循环状态	更新机制可不同，须实测	不按架构名称判意识

6.1 三位异或控制器

考虑 $x^+ = x \oplus r$, $y^+ = y \oplus r$, $r^+ = x \oplus y$ 。在命名式定义下， r 调制 x 、 y 的角色（ $m_x = m_y = 2$ ），又由二者更新，似乎构成极简参照。按本文判据，它不构成参照场。

内在持续。把 x 、 y 的轨迹固定为自然值后翻转 r_t : $r_{t+1} = x_t \oplus y_t$ 不含 r_t ，所以 $L_r = 0$ 。反过来，把 r 的轨迹固定后翻转 x_t : $x_{t+1} = x_t \oplus r_t$ 保留了这一翻转并一直传递，所以 $L_x = H$ （窗内）。参照比内容更短命，判据 3 不成立。

滞后调制。在 t 时刻设定 r_t 后不再夹持， $r_{t+2} = (x_t \oplus r_t) \oplus (y_t \oplus r_t) = x_t \oplus y_t$ ， r_t 恰好被抵消；归纳可得对所有 $s \geq 1$, $r_{t+s} = x_t \oplus y_t$ ，因而 $m_x(s) = 0$ 。 r 只在同一步内调制内容，更适合描述为快速混合变量。

慢变对照。 $x_{t+1} = u_t \oplus r_t$, $y_{t+1} = v_t \oplus r_t$, $r_{t+1} = r_t \oplus (x_t \wedge y_t)$, u, v 为外部输入, 内容通道为 $u \rightarrow x$ 与 $v \rightarrow y$ 。内容每步由输入刷新, $L_x = 0$; r 在固定内容轨迹时按异或累积保留翻转, $L_r = H$ (窗内); 从 $x \wedge y = 0$ 的初态出发, 保持 $u \neq v$ 时后续 $x \wedge y$ 恒为 0, 设定的 r 一直保持, $m_x(s) = 2$ 对所有 $s \geq 1$ 成立。三条判据都满足。

附录 A 对控制器全部初态、慢变系统的有限输入子集做核验; 任意滞后的结论来自上述代数理由, 不由有限枚举替代。新判据降低了过度归属, 但没有消除它: 一个 3 位的慢变系统仍然构成最小参照场。ERF 承认这一后果, 其共享广度只有 2, 但没有据此定义统一的“最低意识”。响应分化依赖所声明的条件集与探针, 不能脱离协议断言 $N_H = 2$ 。

6.2 位点传递的同质网格：与 IIT 分歧

Aaronson 论证, 按 IIT, 由异或门组成的二维方格或扩展图可以具有随规模增长的 Φ (Aaronson, 2014)。Tononi 在回应中接受了这一后果, 认为足够大的二维异或网格确实具有相当程度的意识 (Tononi, 2014)。Aaronson 的计算基于 IIT 早期版本, 但 Tononi 的回应处理的正是网格是否有意识这一核心问题。

命题 6 (协议不变时同一对称轨道的持续画像相同)。 设系统的自同构群在位点上传递: 对任意两个位点 z, w , 存在一个把 z 映到 w 、且保持全部更新规则的位点置换。环、环面, 以及由凯莱图构造的扩展图, 在各位点采用同一规则时都满足这一条件。还要求背景、输入集合、状态干预对及夹持协议在该群作用下封闭。分析时对这些允许条件取上确界。则所有位点的内在持续画像 $\pi_z(s)$ 相同; 若该群还在某一类同形位点块上传递, 则这些块的画像也相同。因此, 在单位点粒度或同形块粒度上, 对任何 R 与 X 的选择, $L_R > L_x$ 都不成立, 判据 3 在该比较类内失败; 不排除跨不同轨道或非同形集体变量的候选。

证明。设 g 是把 z 映到 w 的保规则置换。 g 把每条初态与输入序列一一映到另一条, 并把 z 的干预轨迹映到 w 的干预轨迹, 其余位点的自然轨迹也随之对应。于是翻转 z 所能造成的每一种 z_{t+s} 变化, 都对应翻转 w 时的同一种变化, 反之亦然。对初态取上确界后, $\pi_z(s) = \pi_w(s)$ 。块的情形同理。严格不等式无法成立。□

仅有“同一规则”而没有传递的自同构时, 结论不一定成立: 度数不同的位点可能看到不同的邻居轨迹集合。命题因此不覆盖一般的非正则扩展图。

附录 A 对三种同质系统做了抽样核验: 90 号与 150 号元胞自动机环、异或环面, 每个系统的全部位点都只出现一种内在持续画像。150 号环的每个位点都能长期保持自身状态, 画像恒为 1, 说明命题 6 不依赖“位点没有自我持续”这一特例: 在指定对称轨道内, 协议不变性排除了严格快慢分离。

因此存在明确的条件性张力: 历史 IIT 网格论证允许意识归属, 而 ERF 的严格支持条件在上述对称粒度上不成立。但本文没有为同一网格计算 IIT 4.0 的全部量, 也未排除不同宏观粒度。不能据此宣布二者必有一个被证明为错, 或把有限环面与有边界网格无条件等同。

6.3 广播总线与静默调制器：与 GWT 的比较

纯复制广播若不改变其他内容通道的响应核, 例如 $K_i^r(a)$ 对广播值 r 不依赖, 则 $m_i = 0$ 。然而广播信号进入非线性接收器时也可产生四项交互; 所以“广播”这个名称本身不能推出调制为零。GWT/GNWT 还涉及全局可用性、竞争和动态点燃, 不能用一个复制电路代替完整理论 (Dehaene & Changeux, 2011)。

一个受内容反复更新的慢变共享增益状态, 可以改变各通道映射, 而不把某一具体内容复制到所有模块。若另两条判据也成立, 它是 ERF 的候选组织。这说明内容传播与规则调制可在构造中分

离，不证明两套理论在真实脑系统中互斥。所谓“静默”仅指不广播特定内容，不是完全没有因果信息传递。

6.4 前馈展开网络：与输入输出充分性立场的分歧

把一个递推系统在有限时窗内展开为前馈计算图，可以保留普通输入输出映射。对某一层的状态副本作一次干预，其影响也可以沿后续副本传播，因此不能声称复制一次递推干预必然需要 N 次协调干预。

ERF 所强调的差异在于声明的持续位点：在理想的无自环、无寄存器前馈实现中，固定其他位点后，某个门的局部状态没有递推自保持；有物理存储的循环实现则可能保留。若实际硬件复用寄存器、引入延迟或采用块粒度，须重新分析。软件展开图本身不是物理组织的证明。

这一有条件的区分挑战“普通输入输出等价足以决定体验”的立场，未反驳所有功能主义。Doerig et al. (2019) 的展开论证和 Hanson 与 Walker (2021) 的层级分析提示：扩大到内部扰动证据后，仍须独立说明为何该证据能支持体验归属。Casali et al. (2013) 的扰动复杂度提供临床经验范例，但不解决这一逻辑问题，也不意味着任意等价实现都能由任意扰动区分。

6.5 Transformer 与状态空间模型：与能力导向归属的比较

常规只追加的自回归 Transformer 实现中，既有 KV 条目写入后通常不再改写。若以单条目为位点，该条目缺乏反复内容更新；它是否同时调制两个通道、调制持续多久仍须测量。整个缓存集合不断追加内容，滑窗、压缩和递归记忆也会改变组织，所以不能从单条目只读推出整个 Transformer 不可能存在参照。

选择性状态空间模型（如 Mamba；Gu & Dao, 2023）的循环状态提供输入依赖更新和保持机制；是否形成共享调制、反复内容反馈及较慢持续仍取决于训练和所选干预。附录 B 给出待执行的语言模型协议；附录 C 的小模型不是 Mamba 的实现或大模型实验。

能力相近不保证上述组织画像相同。Hoel (2026) 讨论持续学习与体验归属，其论证不等同于本文的状态更新条件；固定推理权重也不等于状态完全不变。这些比较说明应分别报告能力、学习和运行组织，而不是由架构名推断体验。

6.6 训练依赖性：同一架构的三种画像

本节报告小规模计算实验与概念验证。固定二维状态空间架构和训练超参数，只改变任务，每个任务运行种子 0、1、2，全部九次结果均保留。

模型为 $h_t = A(s_t) \odot h_{t-1} + Bu_t$ ，其中 $A(s) = \tanh(p) + a_1 s$ 。输入包括两个二值内容流、切换事件和框架提示。两个读出均含乘性项 $(v_k \cdot h_t)x_k$ ，使共享调制在架构上成为可能。该 24 参数模型借用了输入依赖递推的思想，不是 Mamba； $A(1)$ 可小于 -1 ，不能假定任意输入下稳定。

- **T1 持续框架：** 初始提示给出 f_0 ，后续切换事件翻转框架，目标为 $y_k = x_k f$ 。
- **T2 框架无关：** 目标为 $y_k = x_k$ ，保留相同输入类型。
- **T3 每步提示：** 目标同 T1，但每步都提供当前框架，减少对历史保持的任务需求。

准确率使用与训练独立的固定测试随机流；组织测量使用另一随机流和明确改变过的输入窗口，不把该窗口当作未经干预的测试分布。经验调制记为 $\bar{m}_k(s)$ ，为 1000 个探针的四项概率对比绝对值的平均，非理论上确界 $m_i(s)$ 。状态保留率记为 $\bar{q}(s)$ ，非总变差持续 $\pi_z(s)$ ；事件更新效应记为 $\bar{u}_s$ ，非完整内容维持判据。

下表是原始交付结果的全部三个种子、两个通道的范围；重跑对照和每次运行详见发布包。范围不代表置信区间。

任务	$\bar{q}(20)$	$\bar{m}_k(1)$	$\bar{m}_k(5)$	$\bar{m}_k(20)$
T1	0.7669–0.7718	1.9826–1.9837	1.9772–1.9788	1.9442–1.9484
T2	6.40×10^{-56} –	2.72×10^{-17} –	2.73×10^{-17} –	2.72×10^{-17} –
	0.2554	0.002451	0.001977	0.000841
T3	0.000319–	1.6471–1.6508	0.001637–	9.50×10^{-7} –
	0.000349		0.001699	1.03×10^{-6}

T1 在关闭切换的测量窗口中保持强共享调制；T2 的调制很小，但种子 0 明确非零，其他种子的结果在浮点精度附近；T3 初始调制较强，随后快速衰减而非严格消失。两个通道的值相近但并不相同。T1 与 T3 主导无切换递推系数约为 0.987 与 0.67，对应近似振幅半衰期约 53 与 1.7 步；这是衰减摘要，不是 L_R 或意识阈值。

有一项实质边界：测量程序翻转的是控制事件 s_t ，并没有证明被调制内容 x_1, x_2 反复维持同一参照。因此不能把 T1 宣布为“完整 ERF”，也不能把 T2 宣布为“绝无参照”。实验支持的结论是：同一架构经不同任务训练后呈现不同组织画像。任务需求与画像的对应是本实验范围内的观察，不是“只有需要框架的任务才会产生参照”的普遍规律。

7 经验预测与反驳条件

前三项挑战体验桥接假说，第四项只检验人工系统组织。检验前须固定干预、粒度、噪声模型、统计方案和体验推断方法；不能在结果不利时任意改换这些条件。

预测	内容	可能构成挑战的结果
P1 选择性去除	破坏慢变共享调制而尽量保留内容处理，参照型体验指标应下降	调制确已消除而可靠的相应体验证据保留，挑战必要性
P2 时间尺度对应	操纵情境调制保持时间，应系统性影响知觉框架的保持	严格控制混杂后未见预期关系，削弱该实现模型
P3 滞后调制画像	独立确认无相应体验的状态，相比清醒状态应缺少相应持续组织	完整候选组织可靠保留却无体验证据，挑战充分性
P4 训练后组织	在已声明任务与接口下测量状态保持、共享调制和反复内容更新	不符合架构直觉时修正组织预期，不推断机器意识

P1 与 DIT 有共同动机，支持 P1 不能单独区分二者。P2、P3 更具体地关注调制的时间画像，但与其他动态理论可能重叠，本文不主张独占这些预测。P3 主要挑战充分性，而非仅凭“无意识时组织还在”反驳必要性。麻醉、无报告和无体验不能直接画等号，必须控制报告能力、觉醒、注意与测量灵敏度。

Casali et al. (2013) 的扰动复杂度刻画响应的分化和整合；P3 关注扰动对后续内容处理的交互影响，二者不相同。附录 C 仅支持 P4 的有限任务训练依赖性，附录 B 尚待实际语言模型检验。即使 P1–P3 获得支持，把结果推广到人工系统仍需额外的跨基质论证。

8 限度与开放问题

1. **粒度与干预。** 读取规则减少任意打包，但不选择唯一自然粒度。宏观干预如何落到微观状态、多个内容读取是否共享同一变量，仍须说明。命题 6 不能跨越其对称轨道条件。
2. **支持持续与振幅慢变。** 严格非零支持对微小残差敏感，不能充分区分慢衰减与快衰减。完整振幅画像补充该不足，却不自动继承总变差量的坐标不变性。规范化、噪声和尺度选择必须公开。
3. **展开论证。** 内部干预可以区分某些行为等价实现，但不能自行证明体验也不同。Hanson 与 Walker (2021) 的批评是本假说必须面对的约束，不是已经解决的异议。
4. **充分性与过度归属。** 三位慢变构造可满足组织条件，小网络难题仍在 (Herzog et al., 2007)。组织画像较简单不等于已经证明它有“较弱体验”，也不等于没有体验。
5. **效价与感受质。** 这些分量不说明愉快、痛苦或具体感觉。任务智能与组织画像分开，不把强能力等同于强意识。
6. **计算证据范围。** 三个种子不是统计充分性保证；训练没有保存用户交付时的环境与权重，原始数值只能按公开程序重跑对照。测量使用有利于保持的无切换窗口，不能推广到任意输入。控制事件更新不等于完整内容反馈。本文没有完成神经科学实验、真实大模型比较或意识验证。

9 结论

ERF 把慢变共享调制、反复内容更新与时间尺度关系组合为一个明确的组织假说。其贡献在于条件清楚的构造、可分离的画像和经验挑战路径；结构对应为桥接猜想提供动机，既不证明必要性，也不证明充分性。

三位控制器、对称网格、广播与调制、前馈展开以及 KV/循环状态比较保留了判别价值，但必须同时声明物理接口、比较粒度和理论范围。小规模训练实验进一步说明：相同架构在不同任务后可以有不同的共享调制和保持画像。有限构造核验、训练证据与体验推断各有不同职责，任何一项都不能由数值阈值替代另一项。

附录 A 核验程序

正文第 3.6、6.1 与 6.2 节的指定有限实例，由随稿提供的程序 erf_verification.py 核对，程序只使用 Python 标准库。给定固定初态与输入的确定性点质量响应，总变差距离只取 0 或 1，四项差分的半 L^1 范数一般可取 0、1 或 2；下表所列极值恰为 0 或 2。

对象	枚举范围	分析窗	核验结论
三位异或控制器	全部 8 个初态	$H = 12$	$L_r = 0, L_x = 12$ (窗内), $m_x(s) = 0$ ($s \geq 1$)
慢变对照系统	8 个初态 × 前 4 步全部输入序列	$H = 12$	$L_x = 0, L_r = 12$ (窗内), $m_x(s) = 2$ ($s \geq 1$)
90 号环, 32 位点	300 个随机初态	$H = 12$	全部位点画像相同, 恒为 0
150 号环, 32 位点	300 个随机初态	$H = 12$	全部位点画像相同, 恒为 1
8×8 异或环面	300 个随机初态	$H = 12$	全部位点画像相同, 恒为 0

对象	枚举范围	分析窗	核验结论
150 号环全局 奇偶	500 个随机初态	12 步	守恒

交互检验必须使用第 3.2 节定义的四项差分。若改用”两组输出的异或是否一致”作为交互判据，对异或门会把真实交互误判为零，这是实现本附录程序时需要避免的错误。

附录 B P4 的待执行语言模型协议

1. 选定参数量和任务可比较的状态空间模型与 Transformer，记录版本、权重、推理实现和硬件粒度。不是只比较架构名称。
2. 明确层、位置、内容通道、候选参照及其干预。替换循环状态或指定 KV 条目后，固定外部输入，记录状态差、读出差与其随滞后的曲线。
3. 在共同背景下分别设定参照对和内容探针对，计算下一词元分布的四项半 L^1 对比。有限样本均值记为 $\bar{m}_i(s)$ ，经验最大值另记；二者均不等于未经穷尽的理论上确界。
4. 反复干预被调制内容，核查其对同一参照的更新效应。分别分析只读条目、追加缓存集合和可改写记忆，不互相代替。
5. 阻断外部返回路径测量局部或声明块的持续；若为连续数值状态，区分范数保留与分布总变差。有限精度只形成检测界限，不能推出严格为零。
6. 报告全部层与预先指定种子、探针数、误差和阴性结果；不设意识阈值。若定义域允许严格持续期计算，报告 L_R, L_x ；否则只报告经验曲线。

本附录未执行。结果只能确定特定模型、粒度和协议下的组织，不能直接判定体验。

附录 C 训练依赖性实验的细节

C.1 模型与训练

状态维度 $D = 2$ ，序列长 30，批量 64。输入 $u_t = [x_{1,t}, x_{2,t}, s_t, c_t]$ ，状态从零开始，

$$h_t = (\tanh p + a_1 s_t) \odot h_{t-1} + B u_t,$$

$$\ell_{k,t} = w_k x_{k,t} + (v_k \cdot h_t) x_{k,t} + \beta_k \cdot h_t + b_k.$$

输出为 $\sigma(\ell)$ ，共 24 个参数。内容独立均匀取 ± 1 ；切换概率 0.1，首步强制为 0；初始框架均匀取正负。T1、T2 仅在首步给提示，T3 每步给当前框架。训练初始化使用 NumPy default_rng(seed) 的均值 0、标准差 0.3 正态分布，同一随机流随后生成每个训练批次。

训练种子固定为 0、1、2；每个任务各运行一次，不筛选种子。损失为所有样本、时刻和通道的平均二元交叉熵，加 $10^{-3} \sum_j \theta_j^2$ 。中心有限差分步长 10^{-4} ；Adam 学习率 0.05，动量 0.9、0.999，分母常数 10^{-8} ，偏差修正，训练 1200 步。没有基于验证集的选模或提前停止；不主张用户交付前从未做过探索性调参。

测试随机流为 default_rng(999)，每个模型 2000 条序列，准确率在 $2000 \times 30 \times 2$ 个二值输出上取平均。与训练随机流独立，各模型共用同种测试输入生成方案。原稿称九个模型均为 100%；本次重跑九次准确率均为 100%，原始 JSON 的全部 171 个数值字段逐项完全一致；环境和逐字段对照记录在 reproduction.json。

C.2 测量协议与符号

组织探针随机流为 `default_rng(123)`，1000 条序列； $T_0 = 5$ 是零基索引，即第六个时刻，滞后为 1、5、10、20。关闭索引 5 至 25（含）的切换事件。T3 把索引 6 以后的提示保持为索引 5 的提示。该人工背景用于隔离保持，不能代表原始任务的平均动态表现。

T1、T2 的备选轨迹只翻转首步提示；T3 的备选轨迹翻转整条提示流，包含干预前的提示历史。两条轨迹在 T_0 的状态分别为 $h^{(0)}, h^{(1)}$ 。之后从这两个状态出发，在完全相同的基准输入下演化；不是持续把两个不同提示流施加到测量窗口。

令 $d_0 = h^{(1)} - h^{(0)}$ ，沿共同输入的递推传播 d_s ，报告

$$\bar{q}(s) = \frac{1}{n} \sum_j \frac{\|d_{s,j}\|_2}{\|d_{0,j}\|_2 + 10^{-12}}.$$

这是范数保留估计，依赖坐标与归一化；当初始差接近 10^{-12} 时分母稳定项显著影响数值，不可据其半衰期或理论 π_z 作强推断。补充诊断报告初始差的范围。

对每个通道在 $T_0 + s$ 分别设 $x_k = 1, -1$ ，在当前状态更新和读出后得到正类概率 $P_{j,k}^{r,a}(s)$ ，报告

$$\bar{m}_k(s) = \frac{1}{n} \sum_j |P_{j,k}^{0,+} - P_{j,k}^{0,-} - P_{j,k}^{1,+} + P_{j,k}^{1,-}|.$$

对于 Bernoulli 输出，该绝对值等于四项分布对比的半 L^1 范数，取值范围 $[0, 2]$ 。输出概率是模型定义的读出核，不是随机采样的确定性类别。均值不等于理论上确界；原始 JSON 的 `mod` 字段保留历史名称，正文统一称经验调制。

`maintain` 字段实际计算索引 5 处将 s 从 0 翻到 1 后的状态相对变化，记为

$$\bar{u}_s = \frac{1}{n} \sum_j \frac{\|a_1 \odot h_{j,T_0-1} + B_{:,2}\|_2}{\|h_{j,T_0}\|_2 + 10^{-12}}.$$

它度量事件更新而不是证明 x_1, x_2 的反复反馈。原稿把它直接称为完整“内容维持”不准确。本次额外对两个内容坐标在索引 5、10、15、20 的干预效应作诊断，完整结果另列；不会把补充诊断当作预先注册实验。

C.3 结果报告与可复现性

原始 `results.json` 按字节保留；`results-rerun.json` 为本次九次重新训练后的测量结果。`reproduction.json` 列出逐字段误差、全部测试准确率、随机种子、环境与比较容差。数值容差仅用于跨运行复现核验，不用于意识归属。参数权重和完整诊断保存在 `computational-evidence.zip` 中。

原始 T2 种子 0 在两个通道、滞后 1 上分别为 0.0003450 和 0.0024508，滞后 20 上为 0.0001111 和 0.0008405；不是零。种子 1、2 的调制约为 10^{-17} ，处于数值消去误差附近，不能据此宣布严格零。T3 在滞后 5 上约为 0.0016–0.0017，在滞后 20 上约为 10^{-6} ，同样不称消失。事件更新效应 T1 约为 2.31–2.32，T2 为 0.0079–0.684，T3 为 1.376–1.393；它们可以大于 1，不是概率。

附录 A 包含穷尽小初态、受限输入枚举与随机抽样；附录 C 包含优化训练与有限探针测量。两类证据不合并为“全部理论已被程序证明”。代码只依赖 Python 与 NumPy，执行命令、版本和全部源文件指纹见方法说明。

写作与方法说明

本文为 TA-TR-2026-10 v1.1，日期 2026-09-20，DOI 为 10.5281/zenodo.22854705，是 v1.0 (10.5281/zenodo.22852885) 的 revised version。两版属于同一 concept (10.5281/zenodo.22852884)，v1.0 的公开文件保持不变。本文不是同行评审成果，不修改三份 Bitcoin Originals。

作者与发表责任人：刘烘炬 (Hongju Liu)，独立研究者，中国深圳。OpenAI ChatGPT 与 Codex 对文献检索、理论推演、代码与思想实验、批判性修订和文稿制作提供了实质辅助。作者承担署名与发表责任；发表授权不被表述为作者另行完成逐行独立审查。本文未进行人体或动物实验，数据来自公开列明的人工任务。

新增原创文稿与代码在作者有权许可的范围内采用 CC BY 4.0；引用文献及字体软件保留各自权利。数据、代码、全部运行与修订说明随稿公开。DOI、格式核验与复现通过不代表意识理论得到证明、全球首创已获认证或 Google Scholar 已收录。

参考文献

- Aaronson, S. (2014). Why I am not an integrated information theorist (or, the unconscious expander). Shtetl-Optimized (博客)，2014 年 5 月。 [原文或出版记录](#)。
- Albantakis, L., et al. (2023). Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms. PLOS Computational Biology, 19, e1011465. [出版记录](#)。
- Aru, J., Suzuki, M., & Larkum, M. E. (2020). Cellular mechanisms of conscious processing. Trends in Cognitive Sciences, 24(10), 814–825. [原文或出版记录](#)。
- Casali, A. G., et al. (2013). A theoretically based index of consciousness independent of sensory processing and behavior. Science Translational Medicine, 5(198), 198ra105. [出版记录](#)。
- Dehaene, S., & Changeux, J.-P. (2011). Experimental and theoretical approaches to conscious processing. Neuron, 70(2), 200–227. [原文或出版记录](#)。
- Doerig, A., Schurger, A., Hess, K., & Herzog, M. H. (2019). The unfolding argument: Why IIT and other causal structure theories cannot explain consciousness. Consciousness and Cognition, 72, 49–59. [原文或出版记录](#)。
- Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. arXiv:2312.00752. [原文或出版记录](#)。
- Hanson, J. R., & Walker, S. I. (2021). Formalizing falsification for theories of consciousness across computational hierarchies. Neuroscience of Consciousness, 2021(2), niab014. [原文或出版记录](#)。
- Herzog, M. H., Esfeld, M., & Gerstner, W. (2007). Consciousness & the small network argument. Neural Networks, 20(9), 1054–1056. [原文或出版记录](#)。

- Hoel, E. (2026). A disproof of large language model consciousness: The necessity of continual learning for consciousness. arXiv:2512.12802v3. [原文或出版记录](#)。
- Leopold, D. A., & Logothetis, N. K. (1999). Multistable phenomena: changing views in perception. *Trends in Cognitive Sciences*, 3(7), 254–264. [出版记录](#)。
- Kleiner, J. (2020). Mathematical models of consciousness. *Entropy*, 22(6), 609. [原文或出版记录](#)。
- Phillips, W. A., Clark, A., & Silverstein, S. M. (2015). On the functions, mechanisms, and malfunctions of intracortical contextual modulation. *Neuroscience & Biobehavioral Reviews*, 52, 1–20. [原文或出版记录](#)。
- Safron, A. (2020). An Integrated World Modeling Theory (IWMT) of Consciousness: Combining Integrated Information and Global Neuronal Workspace Theories With the Free Energy Principle and Active Inference Framework; Toward Solving the Hard Problem and Characterizing Agentic Causation. *Frontiers in Artificial Intelligence*, 3, 30. [原文或出版记录](#)。
- Salinas, E., & Sejnowski, T. J. (2001). Gain modulation in the central nervous system: Where behavior, neurophysiology, and computation meet. *The Neuroscientist*, 7(5), 430–440. [原文或出版记录](#)。
- Suzuki, M., & Larkum, M. E. (2020). General anesthesia decouples cortical pyramidal neurons. *Cell*, 180(4), 666–676.e13. [原文或出版记录](#)。
- Tononi, G. (2014). Why Scott should stare at a blank wall and reconsider (or, the conscious grid). 刊于 Shtetl-Optimized (Aaronson 博客) , 2014 年 5 月。 [原文或出版记录](#)。
- VanderWeele, T. J. (2015). *Explanation in causal inference: Methods for mediation and interaction*. Oxford University Press. [原文或出版记录](#)。
- Vershynin, R. (2018). *High-dimensional probability*. Cambridge University Press. [原文或出版记录](#)。
- Williford, K., Bennequin, D., Friston, K., & Rudrauf, D. (2018). The projective consciousness model and phenomenal selfhood. *Frontiers in Psychology*, 9, 2571. [原文或出版记录](#)。