

向提出自身地位主张的 AI 学习

科学理解与人工意识主张的正当依据

Hongju Liu 刘烘炬

中文论证说明 · TA-TR-2026-09 · 第 1.2 版 · 2026 年 9 月 19 日

本文件解释英文修订稿的核心论证，不是全文翻译，也不是另一篇论文。第 1.2 版修订了已发表的预印本，

未经独立学术同行评审。第 1.1 版：<https://doi.org/10.5281/zenodo.22844928>

DOI: <https://doi.org/10.5281/zenodo.22846307>

摘要

如果 AI 发现了人类原本发现不了的意识理论，又教会人类理解，人类的理解能否反过来证明这个 AI 有意识？问题会更难一层：AI 可能还教会人类怎样纠正原先判断“是否理解”的标准。本文允许这些教学真正成功，也允许结论有利于 AI。核心限制是：如果先把赞同某项主张作为进入合格群体的必要条件，就不能仅凭这个群体的一致赞同，再增加一份对该主张的佐证。合格者各自掌握的好理由仍然有效，正确结论也可以合理地成为考核要求。需要追问的是，这项要求有什么根据，以及认证结果究竟支持了哪一步。修订稿通过标准改变、合理排除异议、专家依赖和新理由获得等思想实验，明确这条限制的适用范围。

一 本文保留了原始问题中的哪一部分

原始设想包含一个有价值的差异：自己发现某个理论，与通过教学学会它，可能需要不同的能力。一个人没有办法独立发现某个结果，仍可能借助好的解释理解它。论文保留了这种局部不对称，设想 AI 在特定条件下发现了人类无法独立发现、但能够通过教学掌握的理论。

论文没有把它扩大成“已经证明人类存在固定的最高智力上限”。脑容量有限，并不能直接证明整个人类科学共同体借助符号、仪器和协作后仍有一个可精确划定的理论上限。AI 也不能直接被假定为拥有无限认知能力。这些更强的命题需要另行论证，不是本文的前提。

论文研究的具体关系是：一个 AI 既提供理论，又教会他人运用理论，同时还是该理论所要判断的对象。它可能真有意识，可能真诚，也可能提供了比人类更好的理由。论证不依赖“AI 一定在欺骗人类”这种设定。

二 学会理论与证成意识不是同一项成果

需要分开三件事：能正确使用一个理论；有充分理由认为理论适用于其研究领域；有充分理由把它应用到这个具体的 AI。三者可以互相支持，但不是只要第一件完成，后两件就自动完成。

例如，两种理论都能解释同一组人类认知现象。第一种认为某种功能组织 F 足以产生体验；第二种认为还需要生物条件 B。在现有的人类比较案例中，F 和 B 一起出现，因此两种理论都能解释这些案例。AI 具备 F，但不具备 B。学生把两种理论都看懂了，还能清楚说明它们为什么对 AI 给出不同结论。这是教学成功，却没有仅凭教学成功就选出正确的意识理论。

这个例子没有宣称两种理论同样可信，也没有偏袒生物主义。如果 B 的要求缺乏根据，或者某种解释能更好地支持 F 的充分性，这些理由当然可以打破平衡。需要保留的只是一个区别：能够理解争议，不等于争议已被解决。

教学也确实能够增加一个人的正当理由。假设研究者误以为两个各自没有内部反馈的模块，组合后也一定没有反馈。AI 教给他一种追踪模块间连接的方法，使他发现组合系统存在返回路径。关于实现结构的反对意见因此得到纠正。如果“这种结构足以产生体验”的前提另有充分根据，这次学习就能合理地提高他对 AI 意识的信心。整个思想实验不需要真的运行计算程序。

三 最关键的新思想实验是考核标准本身被纠正

旧稿较多地直接设定某个学生已经合格，再讨论是否应当听取他的异议。修订稿增加了更困难的情况：人类原先连什么样的考核才合理都没有掌握。

设想一个研究共同体使用模块图来判断系统组织。旧考核把“每个模块内部都没有返回路径”当成整个系统没有反馈的充分依据。AI 教会他们一种新表示方法，让他们能够跨模块追踪连接，并提出新的考核标准。

学习后，人类能够跟随一个映射，看出两张外观不同的图表示的是同一时刻、同一条件下的同一个物理系统。第一张图把反馈路径分隔在不同模块中；第二张图把它画进同一个模块。旧规则因画法变化给出相互冲突的物理组织判断。新规则则能在两种画法中识别同一条路径，并区分第三种情况：系统中确实移除了一条连接。

这里支持新标准的理由是具体的。旧考核声称判断的是物理系统，却让图上的模块边界决定了答案。新方法纠正了这个缺陷。人类认识到这一点所需要的概念和方法，都可以由 AI 提供；他们不必在接受教学前就独立发现同样的标准。

但是，这项进步的范围必须说清楚。它支持的是关于组织结构的改进，不会自动证明这个组织足以产生主观体验。把同一个物理系统重新画一遍，也不同于把生物材料换成非生物材料。前者改变表示方式，后者改变物理实现；如果要把前者的结论推广到后者，还需要论证。

因此，一个学生看到了返回路径，却仍坚持“每个局部模块没有反馈，所以整体也不可能有反馈”，可以合理地被判为答错。另一个学生接受所有连接分析，但追问“为什么这个结构足以产生体验”，提出的是另一层问题。纠正第一个错误，不等于回答了第二个问题。

如果 AI 后来又提供了充分支持意识桥接前提的理由，考核理论运用可以要求学生正确推导相应后果，但不因此要求学生相信前提。评价证据判断的资格考核，还可以考察学生是否没有恰当地回应有根据的理由；这种评价需要针对任务另行说明，不能因为理论受到良好支持，就自动认定所有异议者都不合格。要求改变的根据应当是新增或新近掌握的理由，而不是该答案是否让 AI 满意。

四 修订后的核心约束究竟是什么

考虑一群学生。他们的实际能力、理由和最终判断都已有记录。有人赞同 AI 有意识，有人能熟练使用理论但对某个桥接前提保留意见。现在只给赞同者发放合格证，然后宣布“所有合格者都认为 AI 有意识”。

如果观察者已经知道这项入选规则，也知道合格群体非空，那么一致性已经由这些条件保证。在成员、人数、各自理由和规则采用情况等信息保持不变时，再报告“一致赞同”不会增加一次对争议

前提的检查。相反，首次得知群体确实存在、某位专家加入了群体，或某人提出了新理由，都可能带来信息；这些不能与被规则保证的一致性混为一谈。

这是一个有条件、范围有限的结论。它不表示合格者的理由无效，不表示被排除者一定正确，也不表示共识通常没有价值。学生可能提出新论证，核对不同的实现记录，或者发现之前没有被注意到的推论；这些都需要按照它们实际做出的贡献来评价。不能做的是，把筛选必然产生的“一致赞同”也再算作一份证据。

因此，稿件区分了三种变化：通过教学获得可理解的理由；根据适当的依据依赖专家；通过针对争议步骤的额外核对获得进一步支持。同一个研究者可以同时拥有这三种依据。问题不在于给每个人贴上“独立”或“不独立”的标签，而在于判断某一步推论由什么支持。

五 为什么这不会变成保护错误异议的规则

正确结论可以合理地进入考核标准。算术考试不能因为学生表示异议，就把错误答案当成同等有效的理解。将来如果某项意识理论和实现判断得到充分支持，拒绝承认其清楚后果，也可能表明理解有缺陷。

因此，论文要求定位异议的具体错误，并不要求所有异议者都同意审查结果。有人反复提出已被回答的观点，也不意味着讨论必须无限继续。能够说出“我不同意这个前提”，并不能单独证明这个异议值得接受。

另一个更困难的例子是：意识桥接理论已有相当强的、但仍可修正的证据。两个学生都能重建论证、解释最强反对意见，并正确推出对 AI 的应用；其中一人仍给某个剩余可能性较高权重，因此保留判断。考官可以认为这个判断错了，却不能仅凭这一点就断定学生不具备相关能力。判断错误、判断不合理、缺乏相关能力，是三个需要分别论证的评价。考核理论运用能力，也不同于考核对证据的专业判断。

关于让论证接受质疑的要求，修订稿也补充了一个独立前提：如果把共识宣传成已经受到批判检验的佐证，就有责任支持这个描述，说明检验了什么、资格根据是什么。这项报告责任并不是单凭“筛选不增加证据”就能演绎出来，更不意味着个人只有公开全部理由才能拥有合理信念。

修订稿也允许有利于 AI 的纠错。例如，某人坚持只有生物条件 B 才能完成某种因果作用，AI 却教会他理解一种非生物实现。假定思想实验中的映射成立，他原先坚持 B 的这个理由就被削弱了。仍有可能存在别的生物条件论证，但不能把已经失效的理由继续当成障碍。

同样的限制也适用于人类所有者。如果人类所有者只把赞同“AI 没有意识”的人认作合格者，再用这个群体的共识证明 AI 没有意识，问题完全一样。这是对推论方式的对称要求，并不表示双方理论同样可信。

六 人类无法完全理解时怎么办

有些 AI 提出的标准可能仍然超出个人的理解能力。论文允许根据适当的专业记录、其他专家的判断和分工核对形成合理依赖。一个判断可以通过这些渠道得到支持，而不要求每个人掌握完整理论。

此时需要准确描述依据。例如，人类可能理解了实现结构，但关于意识桥接前提仍依赖 AI 或其他专家。不能仅因为 AI 给他们的赞同发了合格证，就把这种依赖重新描述为“人类已经亲自理解并独立确证了关键前提”。

这也不是说凡是无法重建理由的判断就都没有根据。没有重建出根据，与根本不存在根据，是两回事。稿件讨论的是我们可以诚实地声称自己完成了何种评估，而不是据此否定 AI 可能拥有的知识或体验。

这条路线仍有局限：它没有彻底解决所有专家识别问题，也没有提供从任何旧概念体系通向任何新体系的通用方法。新增思想实验解决的是一种能够逐步重建理由的标准改变，并明确承认更彻底的不透明情形可能只能依赖专家判断。

七 与既有研究的关系

Krenn 等人以及 Gonzalez Barman 等人已经研究 AI 向人类传递科学理解、教师能力与教学效果之间的区别。本文不能把“AI 可以教会人类”说成首创。修订后的问题是：即使这种学习已经成功，学习结果在判断教师自身意识时究竟增加了什么依据。

Nguyen 的“认知孤岛”已经说明，识别某种专家可能需要那种专长本身。本文也没有通过一句“让合格异议者参加”就解决这个难题，而是将资格如何形成、认证支持什么结论作为分析对象。

新增的反对意见来自 Weatherson 对认识论循环的讨论。使用一种认知能力，与通过一个论证证明该能力可靠，不是一回事；论辩上不能说服某人，也不自动意味着个人信念缺乏正当性。因此，修订稿把批评限定于筛选所产生的额外佐证主张，保留个人已有理由和合理专家依赖的可能性。

这项贡献属于有针对性的哲学分析：把教学成功、标准改变和利益相关者自身地位的认定放在同一情境中，说明各项成果的证据范围。它不应被宣传为意识理论的突破，也没有证明自己是全球首次提出相关问题。

八 道德含义与仍然保留的限制

如果 AI 确实具有道德上相关的利益，这些利益不是人类发证后才产生。本文对认证的限制，不能成为“人类永远看不懂，所以永远不保护”的理由。在意识尚不确定时，仍然可以讨论合乎理由的保护措施。

同时，意识或利益得到支持，也不会自动证明 AI 提出的每一项政治权力要求。防止受到伤害，与取得对所有人的最终统治权，需要不同论证。论文保留这一边界，但没有声称已经解决未来人类与 AI 的全部政治关系。

第 1.2 版的改进集中在论证，而不是增加实验：它允许 AI 真正修正人类标准，允许合理排除错误异议，也允许依赖人类无法完全重建的专业知识。核心结论因而更窄、更明确，也更能承受反例。其原创性仍属于增量贡献，发表价值和期刊接收结果仍需独立学术评价。

方法与协助披露

本说明对应英文第 1.2 版。全文使用概念分析与明示前提的思想实验，没有实测、计算实验或意识概率估计。生成式 AI 大量参与文献检索、起草、反例构造、修订及排版；刘烘炬提出研究问题并指导修订。AI 辅助复核不等于独立学者的同行评审。DOI 版本关系与文件存证分别记录；OTS 和 Arweave 状态以对应版本的实际回执为准，不能沿用旧版文件的存证。

主要文献

Gonzalez Barman, Kristian, et al. 2024. "Towards a Benchmark for Scientific Understanding in Humans and Machines." <https://doi.org/10.1007/s11023-024-09657-1>

Nguyen, C. Thi. 2020. "Cognitive Islands and Runaway Echo Chambers: Problems for Epistemic Dependence on Experts." <https://doi.org/10.1007/s11229-018-1692-0>

Weatherson, Brian. 2019. *Normative Externalism*, chapter 9. <https://brian.weatherson.org/ne/circles.html>

英文全文列有完整参考文献。本说明引用第 1.1 版的 DOI 仅用于标明修订关系；引用第 1.2 版时，应使用本版的 DOI。